

Université Paris-Dauphine

Master Ingénierie Statistique et Financière - Apprentissage

Pipeline d'analyse quantitative des marchés financiers

Clustering, classification, régression et analyse de sentiment

Projet final

Cours : Pratique de la Data Science

Groupe : Huimin ZHANG, Chloé DJOUSSA, Astrid BOUA

25 mai 2026

Table des matières

1	Introduction et motivations	1
2	Travaux connexes	1
3	Données et prétraitement	2
3.1	Univers d'entreprises	2
3.2	Collecte des données	2
3.3	Prétraitement	2
4	Clustering	3
4.1	Objectif	3
4.2	Méthodes utilisées	3
4.2.1	K-Means	3
4.2.2	Clustering hiérarchique	3
4.2.3	DBSCAN	4
4.3	Évaluation et résultats	4
5	Classification Buy / Hold / Sell	5
5.1	Objectif	5
5.2	Construction du dataset	5
5.2.1	Labellisation par auto-supervision	5
5.2.2	Indicateurs techniques	5
5.2.3	Améliorations : variables macro-économiques et temporelles	5
5.2.4	Déséquilibre des classes	5
5.3	Algorithmes de classification	6
5.4	Résultats et interprétations	6
6	Prédiction de rendement à J+1	7
6.1	Objectif	7
6.2	Méthodes utilisées	7
6.2.1	Préparation des données	7
6.2.2	Modèles de Machine Learning	8
6.2.3	Réseaux de Neurones Profonds	8
6.3	Résultats	8
7	Analyse de sentiment sur les actualités financières	9
7.1	Objectif	9
7.2	Données et datasets de fine-tuning	9
7.3	Modèles comparés	10
7.4	Résultats	10
7.5	Application : impact des news financières sur les variations de stock	10
8	Stratégie d'agrégation des signaux	11
8.1	Architecture du pipeline	11
8.2	Stratégie d'agrégation pondérée	12
8.3	Calcul du signal de sentiment	12
8.4	Règles de décision	13
8.5	Résultats du pipeline	13
9	Conclusion	14

1 Introduction et motivations

Les marchés financiers sont régis par une multitude de facteurs interdépendants : fondamentaux économiques d'entreprises, dynamiques sectorielles, comportements des investisseurs et flux d'information en temps réel. La prise de décision en matière d'investissement requiert ainsi la synthèse de signaux hétérogènes, souvent difficiles à agréger manuellement.

L'explosion des données disponibles tels que les historiques de cours, les ratios financiers et les actualités financières, et les avancées récentes en apprentissage automatique et en traitement du langage naturel ouvrent de nouvelles perspectives pour l'automatisation et l'amélioration de ces analyses. En particulier, des modèles capables d'apprendre des régularités statistiques à partir de grandes quantités de données peuvent compléter ou, dans certains cas, surpasser les approches analytiques classiques.

L'objectif de ce projet est de concevoir un pipeline modulaire et automatisé permettant, à chaque exécution quotidienne, de produire des recommandations d'investissement fondées sur quatre types de signaux distincts et complémentaires :

1. **Regroupement d'entreprises similaires** (*clustering*) permettant d'identifier des pairs et de faciliter la diversification de portefeuille.
2. **Classification directionnelle** (*Buy / Hold / Sell*) à partir d'indicateurs techniques calculés sur les historiques de cours.
3. **Prédiction du rendement à court terme** (horizon $J+1$) par des modèles de régression, tant classiques que par réseaux de neurones profonds.
4. **Analyse de sentiment** sur les actualités financières récentes grâce à un modèle BERT fine-tuné sur un corpus spécialisé (FinBERT).

L'univers d'investissement retenu comprend 41 entreprises technologiques, financières, industrielles et énergétiques de premier plan à l'échelle mondiale, permettant une analyse véritablement diversifiée.

2 Travaux connexes

Plusieurs travaux académiques ont posé les bases des approches utilisées dans ce pipeline.

Prédiction des cours boursiers par LSTM. Les travaux fondateurs de Hochreiter et Schmidhuber (1997) sur les réseaux LSTM ont été adaptés à la prédiction financière dès les années 2010. Fischer et Krauss (2018) démontrent notamment que les LSTM surpassent les méthodes de mémoire longue classiques sur des séries temporelles de cours d'actions, grâce à leur capacité à capturer des dépendances longues dans les données séquentielles.

Analyse de sentiment et marchés financiers. Les travaux de Bollen, Mao et Zeng (2011) ont établi que l'état émotionnel collectif exprimé sur les réseaux sociaux présente une corrélation avec les variations du DJIA sur un horizon de quelques jours. Plus récemment, Araci (2019) a proposé FinBERT, un modèle BERT pré-entraîné sur un large corpus de textes financiers (rapports d'entreprises, actualités économiques) qui surpasse les modèles généraux pour la classification de sentiment dans le domaine financier.

Clustering d'actifs financiers. Mantegna (1999) a introduit l'utilisation des matrices de corrélations des rendements et des méthodes de clustering hiérarchique pour identifier des groupes d'actifs aux évolutions similaires, posant les bases des stratégies de diversification assistées par l'apprentissage machine.

Ces travaux constituent le socle théorique sur lequel s'appuient les méthodes mises en œuvre dans ce projet.

3 Données et prétraitement

3.1 Univers d'entreprises

L'univers d'investissement étudié comprend 41 grandes entreprises cotées sur les principales places boursières mondiales. La diversité géographique et sectorielle est assurée par la présence d'entreprises américaines (Apple, Microsoft, Amazon, Tesla, NVIDIA, etc.), européennes (ASML, SAP, LVMH, TotalEnergies, Shell, Siemens), asiatiques (Samsung, Sony, Toyota, Tencent, Alibaba, Baidu, BYD, ICBC) et indiennes (Reliance Industries, TCS). Cette sélection couvre les secteurs de la technologie, de la finance, de l'énergie, des biens de consommation et de l'industrie, assurant ainsi une large diversité dans les profils de risque et de rendement.

3.2 Collecte des données

La collecte de données s'effectue via deux sources principales :

Ratios financiers fondamentaux : Pour chaque entreprise, 13 ratios financiers sont récupérés via l'API `yfinance` : forward P/E, beta, price to book, price to sales, rendement du dividende, BPA, dette/capitaux propres, ratio courant, ratio rapide, retour sur capitaux propres (ROE), retour sur actifs (ROA), marge opérationnelle et marge nette. Ces ratios permettent une caractérisation multidimensionnelle du profil financier de chaque entreprise.

Historique des cours : Pour chaque entreprise, 5 années d'historique quotidien des cours de clôture sont téléchargées. À partir de la série de cours, deux colonnes supplémentaires sont calculées : le cours du lendemain (**Next Day Close**, obtenu par décalage temporel), et le rendement journalier (**Daily Return**), défini comme :

$$r_t = \frac{P_{t+1} - P_t}{P_t} \quad (1)$$

où P_t désigne le cours de clôture au jour t .

Actualités financières : Les actualités sont collectées via l'API NewsAPI à partir de sources spécialisées (*Wall Street Journal*, *Bloomberg*, *Financial Post*, *BBC News*, etc.). Pour chaque entreprise, un scraping quotidien a été effectué afin de récupérer un maximum de news, en filtrant par pertinence (mention du nom de l'entreprise dans le titre ou la description) et ont été stockés dans des fichiers JSON organisés par date.

3.3 Prétraitement

Le prétraitement varie selon la tâche analytique. Pour le clustering financier, les valeurs manquantes sont traitées par suppression des entreprises ou des ratios entièrement manquants. Pour les tâches de régression et de classification, les valeurs manquantes résiduelles sont remplacées par la moyenne. Une standardisation par **StandardScaler** (pour les algorithmes sensibles à l'échelle) ou une normalisation min-max par **MinMaxScaler** (pour les réseaux de neurones) est ensuite appliquée.

Pour la classification, les données séquentielles de cours sont enrichies par 9 indicateurs techniques calculés via la bibliothèque `ta` : moyenne mobile simple à 20 jours (SMA-20), moyenne mobile exponentielle à 20 jours (EMA-20), RSI-14, MACD et sa ligne signal, bandes de Bollinger haute et basse, volatilité glissante sur 20 jours, et taux de variation sur 10 jours (ROC-10). Des améliorations ultérieures ajoutent des variables macro-économiques (VIX, taux d'intérêt à 10 ans) et des variables temporelles (mois, jour de la semaine, trimestre).

4 Clustering

4.1 Objectif

Le clustering vise à identifier des groupes d'entreprises aux comportements similaires selon trois dimensions analytiques distinctes : les profils financiers, les profils de risque, et les rendements journaliers.

Les profils financiers sont construits en utilisant les 6 variables financières les plus discriminantes : *forwardPE*, *beta*, *priceToBook*, *returnOnEquity*, *profitMargins* et *operatingMargins*. Les profils de risques sont construits en utilisant les 6 variables de risque : *beta*, *debtToEquity*, *currentRatio*, *quickRatio*, *returnOnAssets* et *dividendYield*. On construit également la matrice de corrélation des rendements journaliers pour l'ensemble des entreprises. La distance entre deux entreprises i et j est définie comme :

$$d_{ij} = 1 - \rho_{ij} \quad (2)$$

où ρ_{ij} est le coefficient de corrélation de Pearson de leurs séries de rendements.

Ces regroupements servent à la construction de portefeuilles diversifiés et constituent également un signal d'entrée pour le pipeline de recommandation.

4.2 Méthodes utilisées

Trois algorithmes de clustering sont comparés : K-Means, le clustering hiérarchique agglomératif (*Ward linkage*) et DBSCAN.

4.2.1 K-Means

K-Means est un algorithme de partitionnement non supervisé qui regroupe les observations en k clusters en minimisant la variance intra-cluster, chaque cluster étant représenté par son centroïde. Le nombre optimal de clusters est déterminé par la méthode du coude, qui consiste à tracer l'inertie intra-cluster en fonction du nombre de clusters k et à identifier le point d'inflexion de la courbe. La détection est automatisée en calculant la dérivée seconde de la courbe d'inertie :

$$k^* = \arg \max_k \Delta^2 \mathcal{I}(k) \quad (3)$$

où $\mathcal{I}(k)$ désigne l'inertie pour k clusters.

La visualisation des clusters est réalisée par projection t-SNE à deux dimensions, permettant une représentation lisible de la structure de voisinage dans l'espace multidimensionnel des ratios standardisés.

4.2.2 Clustering hiérarchique

Le clustering hiérarchique agglomératif est une méthode de classification non supervisée qui construit une hiérarchie de groupes en fusionnant progressivement les observations les plus similaires selon un critère de distance. Le nombre optimal de groupes est déterminé par analyse du dendrogramme : on identifie le plus grand saut de distance entre deux fusions consécutives :

$$k^* = n - \left(\arg \max_i (d_{i+1} - d_i) + 1 \right) \quad (4)$$

où d_i représente la distance à la i -ème fusion, et n le nombre d'entreprises. Ce critère est contraint entre 2 et 6 clusters pour des raisons de stabilité analytique.

4.2.3 DBSCAN

Contrairement aux algorithmes précédents, DBSCAN ne requiert pas de spécifier *a priori* le nombre de clusters et est capable d'identifier des points aberrants (labellisés -1). Une procédure de recherche adaptative est mise en place pour trouver la valeur d'*epsilon* produisant au moins deux clusters valides, en distinguant les données financières (gamme $[0.8, 2.2]$) des matrices de corrélation (gamme $[0.25, 0.6]$).

4.3 Évaluation et résultats

Les performances des trois algorithmes sont comparées à l'aide du *Silhouette Score*, défini pour chaque point i comme :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \tag{5}$$

où $a(i)$ est la distance intra-cluster moyenne et $b(i)$ la distance inter-cluster minimale. Le score global est la moyenne sur tous les points, variant de -1 (mauvais clustering) à $+1$ (clustering parfait).

TABLE 1 – Silhouette scores comparatifs — Clustering

Dataset	K-Means	Hiérarchique	DBSCAN
Profils financiers	0.3412	0.3581	0.4033
Profils de risque	0.4559	0.4243	0.4722
Rendements journaliers	0.2947	0.2814	0.7696




FIGURE 1 – t-SNE du DBSCAN des rendements journaliers

Pour ces trois types de clustering sur les 3 datasets, DBSCAN est plus performant que K-Means et le clustering hiérarchique, avec un silhouette score particulièrement élevé pour le dataset des corrélations des rendements journaliers. Cependant, ce résultat est à nuancer, car comme on peut l'observer sur la figure 1, DBSCAN classe la majorité des entreprises comme des outliers. Le score n'est calculé que sur les points appartenant réellement à un cluster, et

peut donc donner une vision artificiellement optimiste de la qualité du clustering, mais ce n'est pas le cas en réalité.

5 Classification Buy / Hold / Sell

5.1 Objectif

L'objectif de cette partie est de construire un classifieur capable de prédire une consigne (*Buy*, *Hold* ou *Sell*) pour une action à un instant donné, en se basant exclusivement sur des indicateurs techniques calculés à partir de l'historique des cours.

5.2 Construction du dataset

5.2.1 Labellisation par auto-supervision

Les labels sont construits de manière auto-supervisée à partir des rendements réalisés sur un horizon de 20 jours (environ un mois de trading). Pour chaque date t :

$$\ell_t = \begin{cases} \text{Buy} (2) & \text{si } \frac{P_{t+20} - P_t}{P_t} > 5\% \\ \text{Sell} (0) & \text{si } \frac{P_{t+20} - P_t}{P_t} < -5\% \\ \text{Hold} (1) & \text{sinon} \end{cases} \quad (6)$$

Ce seuil de $\pm 5\%$ est cohérent avec les coûts de transaction et la tolérance au risque typique d'un investisseur particulier ou institutionnel.

5.2.2 Indicateurs techniques

Les neuf indicateurs techniques suivants sont calculés via la bibliothèque `ta` : SMA-20 (tendance longue), EMA-20 (tendance réactive), RSI-14 (momentum), MACD et sa ligne de signal (divergence de tendance), bandes de Bollinger haute et basse (volatilité), volatilité glissante sur 20 jours (risque), et ROC-10 (accélération du cours). Ces indicateurs résument l'état du marché pour chaque action à chaque instant, transformant la série temporelle en un problème de classification standard.

5.2.3 Améliorations : variables macro-économiques et temporelles

Afin d'enrichir la représentation des observations, des variables macro-économiques sont ajoutées : le VIX (indice de volatilité implicite du marché américain, proxy de la peur des investisseurs) et le taux d'intérêt des obligations du Trésor américain à 10 ans (TNX). Des variables temporelles (mois, jour de la semaine, trimestre) permettent de capturer d'éventuels effets calendaires.

5.2.4 Déséquilibre des classes

Un problème majeur dans ce type de dataset est le déséquilibre des classes : la classe *Hold* représente typiquement 50 à 60% des observations, tandis que *Buy* et *Sell* sont sous-représentées. Sans correction, les modèles tendent à systématiquement prédire *Hold*, ce qui gonfle l'accuracy globale mais conduit à un recall quasi-nul sur les classes minoritaires. Ce biais est corrigé par l'utilisation de poids de classes inversement proportionnels aux fréquences :

$$w_c = \frac{n_{\text{total}}}{n_{\text{classes}} \times n_c} \quad (7)$$

Ces poids sont passés comme `sample_weight` dans l'entraînement de XGBoost et comme `class_weight='balanced'` pour Random Forest.

5.3 Algorithmes de classification

Cinq algorithmes sont évalués et comparés par une procédure de recherche d'hyperparamètres par grille (`GridSearchCV`) avec validation croisée temporelle (`TimeSeriesSplit`, $k = 5$). Le critère d'optimisation est le F1-macro, plus approprié que l'accuracy en présence de classes déséquilibrées.

- **XGBoost** : un modèle de gradient boosting qui construit séquentiellement des arbres de décision en corrigeant les erreurs résiduelles.
- **Random Forest** : un ensemble d'arbres de décision entraînés sur des sous-ensembles aléatoires des données et des variables. Sa robustesse au surapprentissage en fait un modèle de référence solide.
- **K-Nearest Neighbors (KNN)** : classe chaque point en fonction du vote majoritaire de ses k voisins les plus proches dans l'espace des features. Ce modèle non paramétrique permet de représenter des frontières de décision complexes, mais ses performances diminuent lorsque le nombre de variables devient trop élevé.
- **Régression Logistique** : un modèle linéaire interprétable dont les coefficients peuvent être directement reliés à l'importance des variables.
- **SVM (Support Vector Machine) linéaire** : cherche l'hyperplan de marge maximale séparant les classes. En configuration multiclass, une stratégie *one-vs-rest* est adoptée.

Pour l'explicabilité des prédictions, des analyses SHAP (*SHapley Additive exPlanations*) sont réalisées pour XGBoost, Random Forest et Régression Logistique. Les valeurs SHAP permettent de quantifier la contribution marginale de chaque variable à chaque prédiction individuelle.

5.4 Résultats et interprétations

TABLE 2 – Performances comparatives des classifieurs

Modèle	Dataset	Accuracy	F1-macro
Random Forest	Baseline	0.7629	0.7551
XGBoost	Baseline	0.566	0.5095
KNN	Baseline	0.4246	0.3858
Régression Logistique	Baseline	0.4582	0.2135
SVM linéaire	Baseline	0.4575	0.2119
Random Forest	Enrichi	0.8359	0.8366
XGBoost	Enrichi	0.6511	0.6336
KNN	Enrichi	0.5323	0.5055
Régression Logistique	Enrichi	0.4736	0.2909
SVM linéaire	Enrichi	0.4727	0.2852

L'ajout des variables macro-économiques et temporelles ainsi que la correction du déséquilibre des classes produisent une amélioration significative du F1-macro, en particulier sur les classes *Buy* et *Sell* qui bénéficient d'une meilleure reconnaissance. XGBoost et Random Forest surpassent généralement les autres algorithmes en raison de leur capacité à modéliser des relations non-linéaires complexes entre les indicateurs techniques.




FIGURE 2 – Analyse SHAP de la régression logistique et XGBoost pour la prédiction Sell. Chaque point représente une observation, la couleur indique la valeur de la feature (rouge = élevé, bleu = faible). La position horizontale indique la contribution à la prédiction.

L'analyse SHAP montre deux manières de prendre des décisions sur le marché. D'une part, les modèles simples (**Régression Logistique**, **SVM** et **KNN**) qui se focalisent sur les niveaux de prix absolus (**Close**) et/ou les indicateurs de court terme (comme **RSI_14**). Cette dépendance aux prix bruts rend ces modèles particulièrement sensibles à la multicollinéarité et au bruit du marché.

À l'inverse, le **Random Forest** et **XGBoost** adoptent une logique de gestion des risques bien plus robuste. Ils relèguent le **RSI** et le **MACD** au second plan pour placer la volatilité (**Rolling_Volatility**) au sommet de leur hiérarchie décisionnelle. Pour **Random Forest**, la volatilité agit comme un interrupteur de régime : un marché calme (faible volatilité) valide le *Hold*, tandis qu'une forte volatilité déclenche les signaux d'action (*Buy/Sell*), affinés ensuite par les Bandes de Bollinger (**Bollinger_Low**). Contrairement à **Random Forest**, **Xgboost** priorise le retour à la moyenne (**EMA-20**) pour *Hold* et cherche à acheter au plus bas.

6 Prédiction de rendement à J+1

6.1 Objectif

La prédiction du cours de clôture à J+1 constitue une tâche de régression sur des séries temporelles financières. L'objectif est d'estimer $\hat{P}_{t+1}$ à partir des $n = 30$ cours de clôture précédents, ce qui nous donne une information supplémentaire pour compléter notre analyse.

6.2 Méthodes utilisées

6.2.1 Préparation des données

Pour chaque entreprise, les données sont normalisées par un **MinMaxScaler** ajusté sur les données d'entraînement uniquement, afin d'éviter toute fuite d'information. Les données de test incluent les n derniers jours du set d'entraînement comme contexte, garantissant la continuité de la fenêtre glissante :

$$\mathbf{x}_t = [P_{t-30}, P_{t-29}, \dots, P_{t-1}], \quad y_t = P_t \quad (8)$$

Les données sont divisées en 80% entraînement et 20% test, en respectant l'ordre chronologique.

6.2.2 Modèles de Machine Learning

Quatre modèles sont évalués par recherche d'hyperparamètres par grille avec validation croisée temporelle : XGBoost, Random Forest, KNN et Régression Ridge. Cette dernière offre un modèle linéaire pénalisé qui sert de référence interprétable.

6.2.3 Réseaux de Neurones Profonds

Trois architectures de réseaux de neurones sont comparées, toutes implémentées sous TensorFlow/Keras.

MLP (Multilayer Perceptron) : les 30 prix précédents sont aplatis en un vecteur d'entrée de dimension 30, puis traités par des couches denses successives avec activation ReLU et dropout. Cette architecture traite les données sans notion d'ordre temporel.

RNN (Recurrent Neural Network) : les données sont organisées en séquences 3D (samples, 30, 1) et traitées par des cellules récurrentes **SimpleRNN**. Les RNN sont théoriquement adaptés aux séries temporelles mais souffrent du problème de vanishing gradient pour les dépendances longues.

LSTM (Long Short-Term Memory) : variante des réseaux de neurones récurrents conçue pour mieux capturer les dépendances de long terme dans les séries temporelles. Grâce à un système de portes (oubli, entrée et sortie), le modèle apprend quelles informations conserver, mettre à jour ou ignorer au fil du temps.

Pour chaque modèle, trois configurations de complexité croissante ont été comparées : une architecture simple de référence (couche unique, régularisation minimale) et deux structures plus profondes intégrant du dropout ainsi que des variations d'activation. Le critère de sélection final pour identifier la meilleure architecture est le RMSE calculé sur les données de test normalisées.

6.3 Résultats

TABLE 3 – Résultats de la régression J+1 (Apple, à titre d'exemple)

Modèle	MAE	MSE	RMSE	MAPE (%)
Ridge	2.67	13.47	3.67	1.08
KNN	24.87	894.85	29.91	9.54
Random Forest	14.09	361.41	19.01	5.26
XGBoost	10.20	211.43	14.54	3.81
MLP	4.89	40.80	6.39	1.99
RNN	3.8	23.62	4.86	1.51
LSTM	4.84	39.68	6.30	1.94




FIGURE 3 – Comparaison des prédictions des réseaux de neurones avec les valeurs réelles du cours d'Apple

La tableau 3 montre une nette supériorité des approches de Deep Learning sur les modèles de Machine Learning non linéaires (XGBoost, Random Forest, KNN). Ces derniers échouent à extrapoler les tendances boursières, tandis que les réseaux de neurones capturent efficacement la dynamique temporelle des 30 jours précédents comme on peut l'observer sur la figure 3. Le RNN se distingue d'ailleurs au sein du Deep Learning avec le meilleur RMSE de 4.86.

Le modèle de régression Ridge surpasse l'ensemble des modèles avec un RMSE de 3.67. À un horizon aussi court que $J + 1$, le marché est fortement dominé par une composante autorégressive où le prix futur dépend quasi intégralement du prix de la veille. En éliminant le bruit par sa pénalisation linéaire, Ridge exploite parfaitement cette structure de "marché aléatoire", s'imposant comme la solution la plus robuste face au risque de surapprentissage propre aux architectures profondes.

7 Analyse de sentiment sur les actualités financières

7.1 Objectif

Cette partie vise à évaluer le ton des actualités financières récentes collectées pour chaque entreprise via l'API NewsAPI. Elle repose sur le fine-tuning de modèles pré-entraînés de type BERT sur un corpus de données financières annotées.

7.2 Données et datasets de fine-tuning

Deux datasets publics disponibles sur la plateforme HuggingFace sont utilisés pour le fine-tuning :

Twitter Financial News Sentiment (`zeroshot/twitter-financial-news-sentiment`) : un corpus de tweets financiers annotés en trois classes (Négatif, Neutre, Positif), particulièrement adapté au style court et informel des actualités.

Financial Phrase Bank (`nickmuchi/financial-classification`) : un corpus de phrases issues de rapports financiers et de sources économiques, annoté selon le même schéma triclasse. Ce corpus couvre un registre plus formel et technique.

Ces deux datasets sont concaténés pour constituer un corpus d'entraînement plus large et diversifié, couvrant à la fois le langage informel des réseaux sociaux et le langage technique des rapports financiers.

7.3 Modèles comparés

BERT (bert-base-uncased) est un transformeur bidirectionnel pré-entraîné sur un large corpus généraliste par masquage de tokens et prédiction de la phrase suivante. Malgré l'absence de pré-entraînement spécialisé en finance, le fine-tuning sur le corpus combiné lui permet d'acquérir une bonne compréhension du vocabulaire financier.

FinBERT (ProsusAI/finbert) est une variante de BERT pré-entraînée sur un corpus financier de 1,8 million d'articles provenant de Reuters, Bloomberg et *Financial Times*, en plus du corpus généraliste de BERT. Ce biais de domaine lui confère une meilleure compréhension initiale du jargon financier.

Les deux modèles sont fine-tunés pendant 2 epochs, à partir de 3 epochs il y a de l'overfitting.

7.4 Résultats




FIGURE 4 – Comparaison des performances de BERT et FinBERT fine-tunés sur le corpus combiné

Comme on s'y attend, FinBERT a de légères meilleures performances que BERT grâce à son pré-entraînement sur des données financières. La représentation d'entités financières (noms d'entreprises, termes boursiers, acronymes) bénéficie directement de ce biais de domaine.

Pour la suite, on utilise alors le modèle FinBERT finetuné.

7.5 Application : impact des news financières sur les variations de stock

On applique la classification sur les news scrappées afin de visualiser les possibles corrélations entre les sentiments prédits sur ces news et les variations des stocks.

L'alignement temporel des actualités avec les heures d'ouverture du marché de New York (NYSE) suit les règles suivantes :

- les articles publiés entre 9h30 et 15h sont associés à leur heure de publication
- ceux publiés entre 15h et minuit sont ramenés à 15h le même jour
- ceux publiés entre minuit et 9h30 sont associés à 15h la veille.



FIGURE 5 – Superposition des sentiments prédits et du cours horaire de Meta depuis le 1^{er} janvier 2025. Les points verts, dorés et rouges représentent respectivement les articles positifs, neutres et négatifs. Les clusters de points rouges avant une baisse significative témoignent d’une corrélation plausible entre sentiment négatif et baisse des cours.

En comparant les prédictions de FinBERT de base et FinBERT fine-tuné de la figure 5, on observe que le modèle fine-tuné produit une répartition des sentiments légèrement plus contrastée que la version de base, avec davantage de classifications négatives sur les périodes de baisse et une meilleure séparation visuelle entre phases positives et négatives. Cela suggère que le fine-tuning sur le corpus financier combiné améliore la sensibilité du modèle aux signaux sémantiques propres aux actualités économiques et boursières.

On observe parfois une cohérence entre les sentiments prédits par le modèle fine-tuné et les mouvements du cours de Meta, notamment entre Mars et Mai 2026, où les articles sont classés comme positifs avant que le cours augmente et négatifs avant qu’il diminue. Cependant, cette corrélation reste toutefois imparfaite et ne permet pas à elle seule d’expliquer les variations observées du prix de l’action. Le prix d’une action dépend de nombreux facteurs exogènes (résultats trimestriels, politique monétaire, contexte macroéconomique, annonces sectorielles ou mouvements globaux du marché) qui ne sont pas capturés uniquement par le sentiment des news. Les prédictions de sentiment constituent donc davantage un indicateur complémentaire de dynamique de marché qu’un signal prédictif suffisant à lui seul.

8 Stratégie d’agrégation des signaux

8.1 Architecture du pipeline

Le pipeline quotidien intègre les quatre modules analytiques décrits précédemment en un système de recommandation unifié. Pour chaque entreprise, les étapes suivantes sont exécutées :

1. Téléchargement des données de cours récentes (90 derniers jours)
2. Calcul des indicateurs techniques et prédiction du label de classification
3. Prédiction du cours à $J+1$ et calcul du rendement prédit
4. Collecte et analyse de sentiment des actualités : en priorité les articles publiés le jour même, avec repli automatique sur les trois dates les plus récentes disponibles si aucune actualité n’est trouvée pour la date du jour
5. Identification des entreprises similaires par clustering K-Means sur les profils financiers
6. Calcul du score agrégé et formulation de la recommandation

8.2 Stratégie d'agrégation pondérée

Le score de recommandation final est une combinaison linéaire pondérée de trois signaux normalisés dans $[-1, +1]$:

$$\text{Score} = w_{\text{cls}} \cdot s_{\text{cls}} + w_{\text{reg}} \cdot s_{\text{reg}} + w_{\text{sent}} \cdot s_{\text{sent}} \quad (9)$$

où :

- $s_{\text{cls}} \in \{-1, 0, +1\}$ est le signal de classification (Sell, Hold, Buy)
- $s_{\text{reg}} = \text{clip}(10 \times r_{\text{prédit}}, -1, +1)$ est le signal de régression (rendement prédit J+1 normalisé)
- $s_{\text{sent}} \in [-1, +1]$ est la moyenne des sentiments des articles du jour (au plus 20), remappés en $\{-1, 0, +1\}$ selon la correspondance Négatif $\rightarrow -1$, Neutre $\rightarrow 0$, Positif $\rightarrow +1$.

Les poids retenus sont :

TABLE 4 – Poids d'agrégation des signaux

Signal	Source	Poids	Justification
Classification	Meilleur classifieur	40%	Signal directionnel principal
Régression J+1	Meilleur régresseur	35%	Quantification du rendement attendu
Sentiment news	FinBERT fine-tuné	25%	Signal d'information complémentaire

La classification reçoit le poids le plus élevé car elle est directement optimisée pour la prise de décision. La régression apporte une quantification du rendement attendu, complémentaire au signal binaire. Le sentiment reçoit un poids moindre en raison de la latence inhérente à la publication des actualités et de la plus forte variabilité des prédictions de sentiment.

8.3 Calcul du signal de sentiment

Le signal de sentiment est calculé à partir des articles du jour courant uniquement, afin de garantir que seule l'information disponible à la date d'exécution du pipeline influence la recommandation. Si aucun article n'est disponible pour la date du jour, un repli automatique est opéré sur les trois dates les plus récentes présentes dans le fichier JSON de l'entreprise. Dans les deux cas, au plus 20 articles sont analysés (les plus récents). Ce choix assure une robustesse opérationnelle tout en préservant la pertinence temporelle du signal.

Les titres et descriptions de chaque article sont concaténés en un seul texte avant tokenisation, puis classifiés par FinBERT fine-tuné. Le score final est la moyenne des sentiments normalisés :

$$s_{\text{sent}} = \frac{1}{N} \sum_{i=1}^N (c_i - 1), \quad c_i \in \{0, 1, 2\} \quad (10)$$

où N est le nombre d'articles analysés et c_i la classe prédite pour l'article i .

En complément du score agrégé, le pipeline exporte dans le fichier CSV de sortie le nombre d'articles du jour (`today_news_count`) ainsi que la liste des titres (`today_news_titles`), permettant une traçabilité complète du signal de sentiment.

8.4 Règles de décision

Règles de recommandation finale :

Score $> +0.15 \Rightarrow$ **BUY**

Score $< -0.15 \Rightarrow$ **SELL**

Sinon $\Rightarrow$ **HOLD**

Les seuils de ± 0.15 créent une zone neutre centrale permettant d'éviter les faux signaux en cas de signaux contradictoires. Cette conception prudente est cohérente avec l'incertitude inhérente aux prédictions sur des marchés financiers efficaces.

8.5 Résultats du pipeline




FIGURE 6 – Tableau de bord des recommandations générées par le pipeline pour 10 entreprises. Les barres vertes indiquent un signal BUY, rouges un signal SELL, et dorées un signal HOLD. Les lignes pointillées matérialisent les seuils de décision (± 0.15).

TABLE 5 – Résultats du pipeline d'analyse financière

Entreprise	Classification	Rendement (%)	Sentiment	Score Final	Recommandation
Apple	Sell	-1.58	-0.667	-0.6222	SELL
Visa	Sell	0.13	0.000	-0.3954	SELL
Samsung	Sell	-2.02	0.667	-0.3039	SELL
Microsoft	Sell	0.03	0.400	-0.2989	SELL
SoftBank	Hold	-3.19	0.000	-0.1117	HOLD
Shell	Hold	-0.25	0.000	-0.0087	HOLD
Toyota	Hold	0.43	0.667	0.1818	BUY
Intel	Buy	-0.79	-0.250	0.3098	BUY
Meta	Buy	-0.07	-0.333	0.3145	BUY
SAP	Buy	0.23	0.667	0.5749	BUY

Les résultats du pipeline final illustrent la capacité du système à produire des recommandations différenciées à partir de signaux hétérogènes.

Apple concentre les trois signaux les plus négatifs simultanément : classification Sell, rendement prédit de -1.58% et sentiment fortement négatif de -0.667 , ce qui produit le score final le plus bas du tableau de -0.622 et constitue le signal le plus cohérent et le plus fiable du lot. À l'inverse, Samsung illustre une situation de signaux contradictoires : malgré un sentiment positif ($+0.667$), la classification Sell et un rendement prédit de -2.02% donnent le score agrégé de -0.304 , soulignant l'importance de la pondération choisie pour arbitrer entre des sources d'information divergentes.

Toyota représente un cas particulièrement intéressant : la recommandation **BUY** émerge d'une classification Hold, compensée par un sentiment positif fort ($+0.667$) et un léger rendement prédit positif. Le score de $+0.182$, proche du seuil de $+0.15$, indique cependant un signal faible dont la robustesse est à surveiller. Intel et Meta, en revanche, reçoivent un signal BUY porté exclusivement par la classification, malgré des sentiments et rendements prédits légèrement négatifs, confirmant la prépondérance du signal de classification dans notre architecture d'agrégation.

Enfin, SAP présente le profil le plus convaincant côté achat, avec une convergence des trois signaux : classification Buy, rendement prédit positif de $+0.23\%$ et sentiment positif de $+0.667$, produisant le score le plus élevé de $+0.575$. Ce type de convergence multi-signal est précisément la situation dans laquelle la stratégie d'agrégation est la plus fiable.

9 Conclusion

Ce projet a permis de concevoir et d'implémenter un pipeline complet d'analyse quantitative des marchés financiers, combinant des techniques variées d'apprentissage automatique et de traitement du langage naturel. L'architecture modulaire développée couvre l'ensemble de la chaîne de valeur : collecte et prétraitement des données, analyse exploratoire par clustering, prédictions supervisées et agrégation des signaux en recommandations opérationnelles.

La combinaison de signaux hétérogènes (fondamentaux, techniques, macroéconomiques, textuels) constitue l'apport principal de ce travail par rapport aux approches unimodales classiques. Chaque signal porte une information distincte et partiellement complémentaire : la classification capture les patterns techniques de court terme, la régression quantifie le rendement attendu et le sentiment enrichit l'analyse par des informations non structurées

provenant du flux d'actualités.

Néanmoins, plusieurs limites fondamentales doivent être soulignées. La prédiction des marchés financiers reste intrinsèquement difficile en raison de leur complexité, de leur adaptation aux stratégies connues et des chocs exogènes imprévisibles. Les modèles développés ne constituent pas des oracles financiers mais des outils d'aide à la décision devant être utilisés avec prudence dans le cadre d'une stratégie d'investissement plus large. L'absence de backtesting rigoureux sur des données hors-échantillon et le risque de surapprentissage sur la période d'entraînement sont des limitations importantes qu'il conviendrait d'adresser avant toute utilisation en conditions réelles.

Enfin, les poids d'agrégation retenus (40%, 35%, 25%) constituent un choix pragmatique initial qui mériterait une validation empirique plus rigoureuse. L'optimisation de ces poids par backtesting représente la piste d'amélioration la plus directement accessible et potentiellement la plus impactante.

Références

- [1] Hochreiter, S. et Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation, 9(8), 1735–1780.
- [2] Fischer, T. et Krauss, C. (2018). *Deep learning with long short-term memory networks for financial market predictions*. European Journal of Operational Research, 270(2), 654–669.
- [3] Bollen, J., Mao, H. et Zeng, X. (2011). *Twitter mood predicts the stock market*. Journal of Computational Science, 2(1), 1–8.
- [4] Araci, D. (2019). *FinBERT : Financial Sentiment Analysis with Pre-trained Language Models*. arXiv preprint arXiv :1908.10063.
- [5] Mantegna, R.N. (1999). *Hierarchical structure in financial markets*. The European Physical Journal B, 11(1), 193–197.
- [6] Devlin, J., Chang, M.-W., Lee, K. et Toutanova, K. (2019). *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*. Proceedings of NAACL-HLT 2019, 4171–4186.
- [7] Chen, T. et Guestrin, C. (2016). *XGBoost : A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD Conference, 785–794.
- [8] Lundberg, S. et Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. Advances in Neural Information Processing Systems, 30.